PROYECTO 01 · AGENTES INTELIGENTES

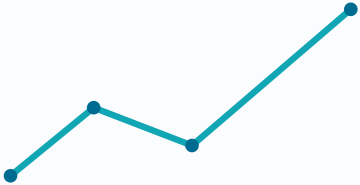
Aprendizaje por refuerzo Q-learning, DQN y Double DQN

Comparación experimental en CartPole y Acrobot

Kevin Erazo **Steven Rodríguez**

33 entrenamientos reales · 4,5 millones de interacciones

https://github.com/Steven735-star/rl-benchmark-lab



Problema y preguntas de investigación

¿Mayor complejidad implica mejor aprendizaje?

Comparamos métodos tabulares y redes profundas, observando desempeño final y estabilidad entre ejecuciones independientes.

- **RQ1:** ¿Cómo influye discretizar el estado con 6, 10 o 20 intervalos frente a DQN?
- **RQ2:** ¿Cómo afectan learning rate, exploración y red objetivo a DQN?
- **RQ3:** ¿Double DQN mejora el resultado y su consistencia?

CartPole-v1

4 observaciones continuas · 2 acciones
Equilibrar una barra · retorno objetivo ≥ 475.

Acrobot-v1

6 observaciones continuas · 3 acciones
Impulsar el sistema hasta la altura meta · objetivo ≥ -100.

Algoritmos: de la tabla a Double DQN

Q-learning tabular

Discretiza las 4 observaciones de CartPole y actualiza una tabla de valores de acciones.

$\delta = r + \gamma(1-d)\,\text{máx}_{a'}\,Q(s',a') - Q(s,a)$

$Q(s,a) \leftarrow Q(s,a) + \alpha\,\delta$

$6^4 = 1.296$; $10^4 = 10.000$; $20^4 = 160.000$ estados.

DQN

Reemplaza la tabla por una red MLP **128–128 ReLU**, entrenada con *experience replay* y una *target network*.

Double DQN

Separa *selección* y *evaluación* de la próxima acción para reducir el sesgo de maximización:

$a^* = \arg\text{máx}_{a'}\,Q_\theta(s',a')$

$y = r + \gamma(1-d)\,Q_{\theta^-}(s',a^*)$.

Parámetros principales: $\gamma = 0{,}99$; DQN con Adam LR $5 \cdot 10^{-4}$, *replay* de 50.000 transiciones, batch 64 y copia de la red objetivo cada 1.000 pasos.

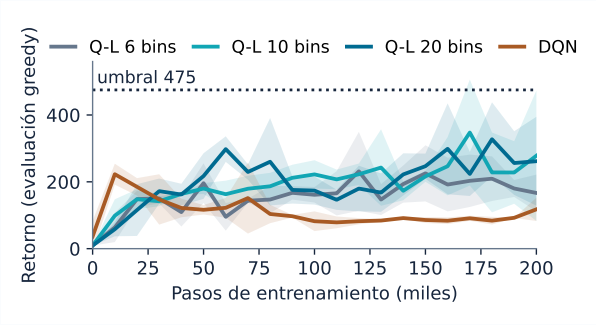
Diseño experimental y evaluación justa

Bloque	Configuraciones	Corridas	Pasos/corrida
Tier 1	CartPole: Q-learning con 6, 10 y 20 bins; DQN	12	200.000
Tier 2	Acrobot: DQN base; LR baja/alta; ϵ corto/largo; sin target	18	100.000
Tier 3	Acrobot: Double DQN frente al DQN base	3	100.000

11	**33**	**4,5 M**
configuraciones	ejecuciones	pasos de entrenamiento

Control experimental: semillas 0, 1 y 2; presupuesto fijo por bloque. **Evaluación:** cada 10.000 pasos (10 episodios greedy) y al final (100 episodios greedy por semilla).

Tier 1 · CartPole: Q-learning frente a DQN



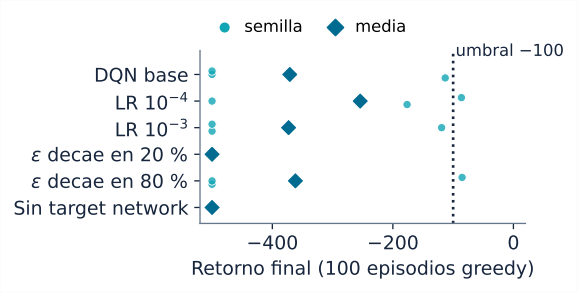
Evaluaciones periódicas (10 episodios): media ± DE entre 3 semillas.

Método	Media final	Éxitos
Q-L, 6 bins	161,80	0/3
Q-L, 10 bins	275,68	1/3
Q-L, 20 bins	**280,87**	0/3
DQN	117,46	0/3

DQN alcanzó **222,80** de media periódica a los 10.000 pasos, pero terminó con solo **117,46** en la evaluación final.

Hallazgo: 20 bins produjo la mejor media; 10 bins obtuvo el único éxito final de CartPole (497,22 en la semilla 1). La ventaja entre 10 y 20 bins no es robusta.

Tier 2 · Acrobot: sensibilidad de DQN



Retorno final por semilla y media de cada variante de DQN.

Variante	Media	Éxitos
DQN base	−371,05	0/3
LR 10^{-4}	−254,25	1/3
LR 10^{-3}	−373,04	0/3
ϵ 20 %	−500,00	0/3
ϵ 80 %	−361,72	1/3
Sin target	−500,00	0/3

Se varía **un factor a la vez** y se conservan las tres semillas, incluidas las fallidas.

Hallazgo: LR 10^{-4} mejoró la media sin éxito generalizado. El decaimiento rápido de exploración terminó en −500 en las tres semillas.

Ablación: ¿qué sucede sin red objetivo?

DQN con target network

$-371{,}05$

Media final entre las 3 semillas; ninguna alcanzó el umbral.

DQN sin target network

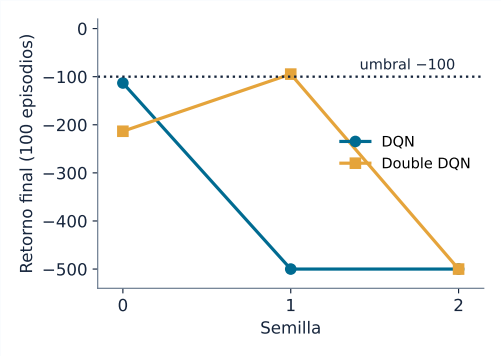
$-500{,}00$

Resultado final idéntico para las tres semillas; 0/3 éxitos.

Interpretación: mantener una copia más estable de los valores objetivo se asocia con mejor rendimiento en este diseño. El *replay buffer* siguió activo durante la ablación.

Precaución: no se demuestra superioridad universal ni un mecanismo causal de inestabilidad.

Tier 3 · Double DQN: mejora media, no robusta



Seed	DQN	DDQN	Δ
0	−113,15	−213,49	−100,34
1	−500,00	−94,64	+405,36
2	−500,00	−500,00	0,00
Media	−371,05	−269,38	**+101,67**

Double DQN usa la red *online* para elegir la acción y la red objetivo para valorar esa acción.

Resultado: mejora descriptiva de **101,67 puntos**, pero empeora en una semilla, mejora en otra y empata en la tercera. Con $n = 3$ no se puede demostrar superioridad estadística.

Lectura crítica: éxitos, estabilidad y límites

4 / 33

ejecuciones superaron su umbral final

0 / 11

configuraciones exitosas en las tres semillas

- **Rendimiento temprano ≠ éxito final:** los checkpoints finales pueden ser peores que los intermedios.
- **Alta varianza:** solo tres semillas por condición; las medias no establecen superioridad robusta.
- **Instrumentación limitada:** no se guardaron curvas de error TD ni valores Q para diagnosticar causas.

Alcance: Q-learning tabular escala mal con estados continuos; DQN convencional requiere acciones discretas. En locomoción con torques continuos serían más adecuados enfoques como PPO, SAC o TD3 (análisis teórico, no entrenado).

Conclusiones y evidencias reproducibles

1 · La representación importa.
Q-learning tabular (10 y 20 bins) superó la media final de DQN en CartPole, sin éxito consistente.

2 · La estabilidad importa.
La red objetivo y la exploración influyeron en Acrobot; las mejoras tempranas no siempre persistieron.

3 · Double DQN no garantiza convergencia.
Mejoró la media observada, pero los resultados dependieron de la semilla.

Código + resultados

Repositorio público con **33 JSON**, **66 CSV**, **33 checkpoints** y figuras originales.

github.com/Steven735-star/rl-benchmark-lab

Idea clave: un buen resultado en una ejecución no implica aprendizaje estable. **Trabajo futuro:** más semillas, diagnóstico de valores Q y validación independiente de checkpoints.